Análisis integral — NYC Yellow Taxi

Viajes Yellow Taxi publicados por NYC TLC, 2019–último mes oficial disponible

Table of contents

Propósito, alcance y etiqueta de evidencia . . . 1
Intake, diccionario y trazabilidad . . . 2
Análisis diagnóstico: calidad, cobertura y límites de la fuente . . . 2
Análisis descriptivo: demanda, estacionalidad y cambios de régimen . . . 3
Exploración abierta: patrones habilitados por los datos . . . 4
- Estabilidad entre regímenes . . . 5
- Economía observada y asociaciones . . . 6
- Rutas y hallazgos no cerrados . . . 7

Matriz de evidencia y ramas exploradas . . . 7
Análisis predictivo: evaluación temporal . . . 7
Análisis prescriptivo condicionado . . . 9
Hallazgos y conclusiones . . . 9
- F01 — Calidad e integridad . . . 9
- F02 — Demanda temporal . . . 9
- F03 — Geografia . . . 10
- F04 — Economia y pagos . . . 10
- F05 — Prediccion . . . 10
- F06 — Prescriptiva . . . 10
- Conclusión de cierre . . . 11

Límites y transición . . . 11

Propósito, alcance y etiqueta de evidencia

Este documento estudia los viajes Yellow Taxi publicados por NYC TLC desde 2019 hasta el último mes local disponible. Distingue evidencia **descriptiva**, asociaciones, resultados **predictivos** y escenarios condicionados. No identifica causalidad ni estima el efecto de políticas, conductores, precios o incentivos.

La fuente cruda combina el manifiesto congelado 2019–2024 con los meses oficiales descubiertos localmente. El manifiesto y las reglas de inmutabilidad se encuentran en `data/raw/nyc_tlc_yellow_2019_2024/`; `manifest_discovered.csv` registra los meses posteriores descargados, su tamaño y SHA-256 local.

El documento calcula la actualización de cobertura y patrones descriptivos directamente desde los Parquet locales. Las tablas de evidencia histórica y la validación predictiva en `reports/` permanecen congeladas para 2019–2024 y 2022–2024, respectivamente, hasta una nueva evaluación formal.

Intake, diccionario y trazabilidad

La unidad observada es un viaje publicado por TLC. Los campos se han perfilado en `reports/observed_schema.csv`; las diferencias de esquema entre períodos se preservan mediante lectura Parquet con unión por nombre. El catálogo de zonas es el archivo oficial `taxi_zone_lookup.csv`.

La cobertura se limita a viajes Yellow Taxi publicados, no a todos los desplazamientos de Nueva York. Las zonas se interpretan con el catálogo TLC y los cambios de esquema entre meses se tratan como una condición de la fuente, no como una señal de comportamiento.

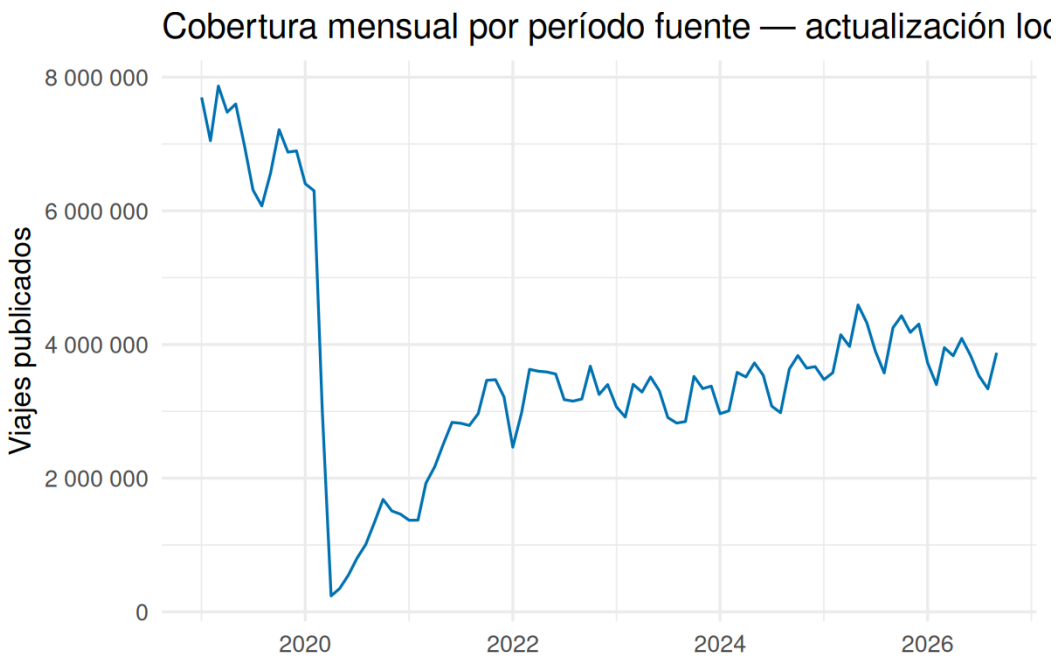
Análisis diagnóstico: calidad, cobertura y límites de la fuente

```
  meses_disponibles primer_periodo ultimo_periodo viajes_publicados
1                93        2019-01        2026-09         341589889
  timestamps_fuera_de_periodo
1                       11309
```

Modo de ejecución: **Parquet locales: actualización descriptiva**. El último período disponible para esta ejecución es 2026-09; cualquier resultado predictivo congelado conserva su ventana de evaluación original hasta ser reentrenado y reevaluado.

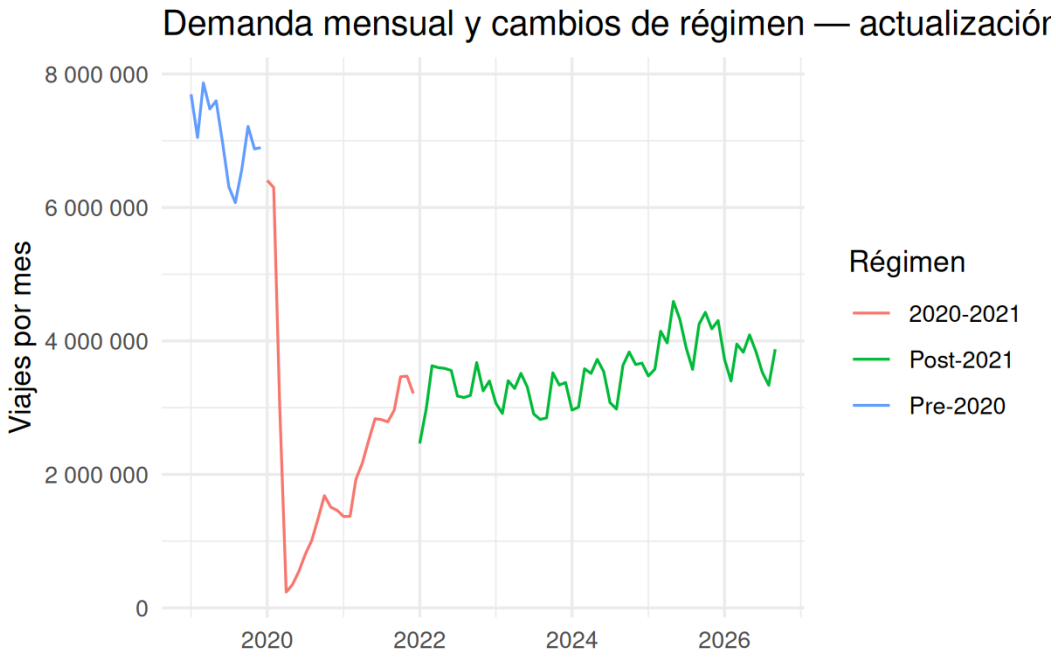
```
# A tibble: 1 x 6
      trips missing_pickup timestamp_outside_source_per~1 negative_distance
      <dbl>          <dbl>                           <dbl>             <dbl>
1 259287888              0                           10927             11440
# i abbreviated name: 1: timestamp_outside_source_period
# i 2 more variables: negative_duration <dbl>, negative_total <dbl>
```

La tabla anterior presenta los controles antes de aplicar filtros analíticos. En particular, los registros cuyo timestamp no coincide con el mes declarado por el archivo permanecen contabilizados en la auditoría; se excluyen únicamente de las series temporales para que no desplacen artificialmente la demanda entre períodos.

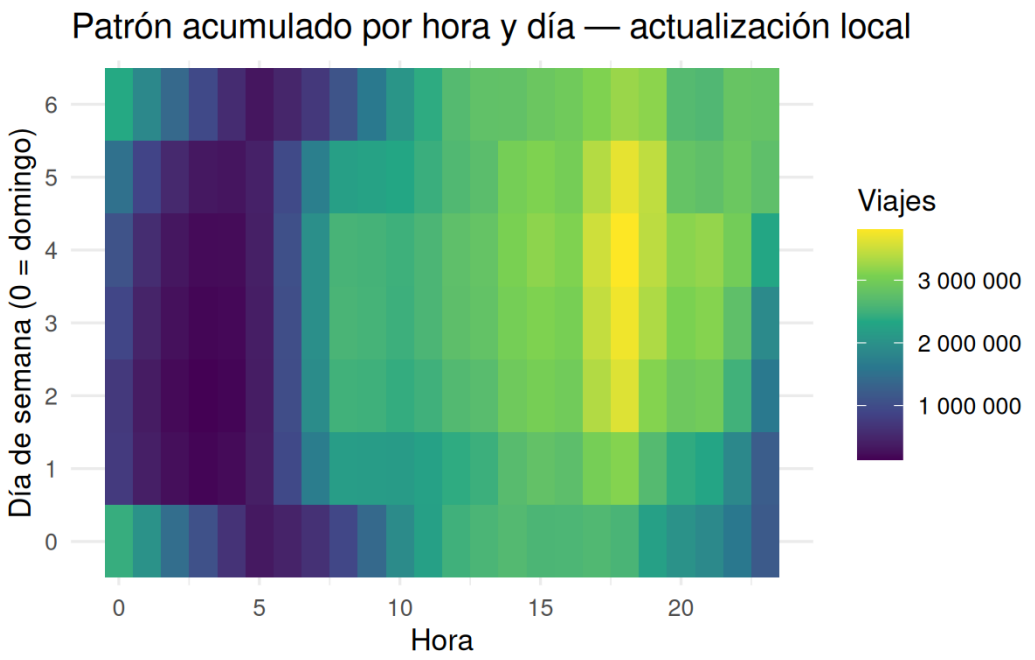


La cobertura muestra la ruptura visible durante 2020–2021 y los meses oficiales incorporados después de 2024. Esa discontinuidad es material para cualquier comparación histórica: por eso las métricas posteriores se interpretan por régimen temporal y no como una única serie estable.

Análisis descriptivo: demanda, estacionalidad y cambios de régimen



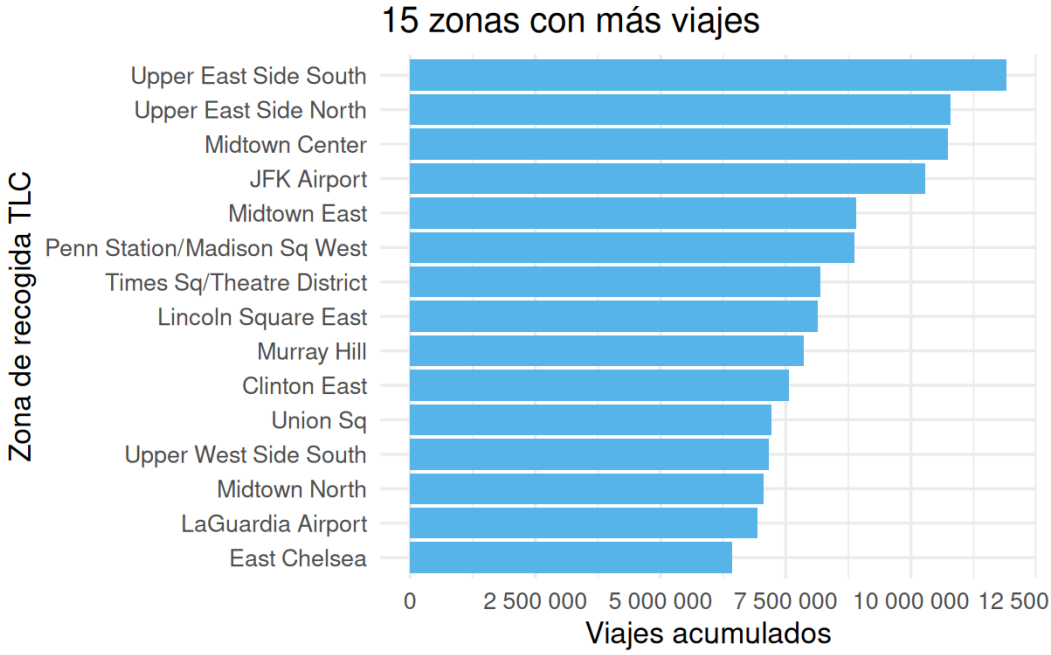
La serie confirma cambios de nivel persistentes y una ruptura material durante 2020–2021. La separación por régimen organiza la comparación histórica, pero no explica las causas de esos cambios.



El mapa de calor resume la estacionalidad semanal promedio. Es útil para describir cuándo se concentra la demanda registrada; no permite inferir disponibilidad de vehículos, tiempos de espera ni demanda no atendida.

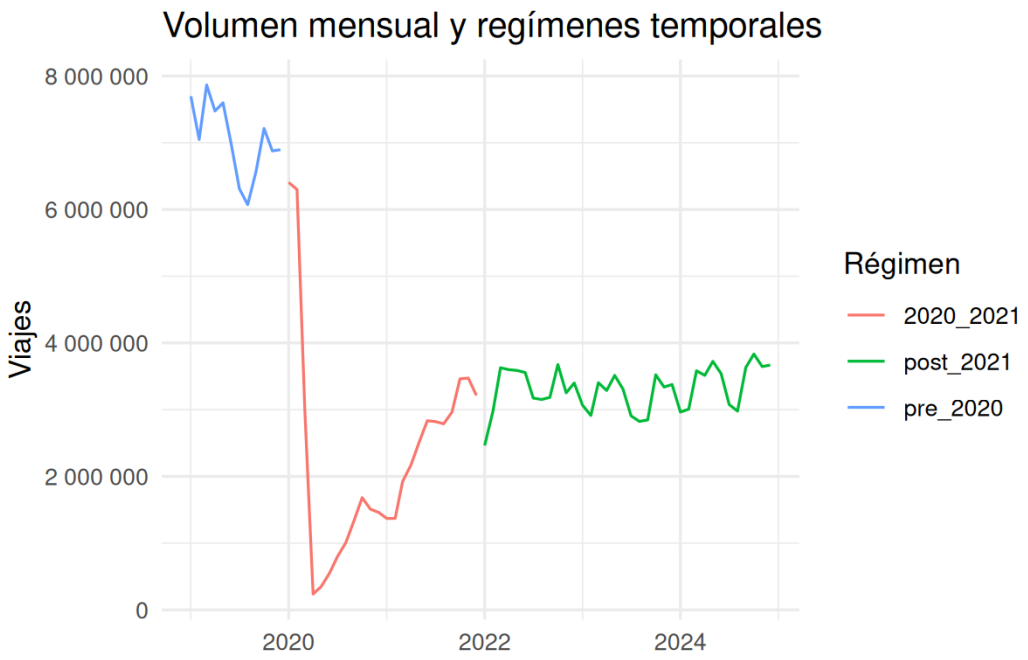
Exploración abierta: patrones habilitados por los datos

Esta sección no parte de una respuesta esperada. Explora concentración espacial, cambios de estabilidad por año, trayectos frecuentes y relaciones entre volumen, distancia, duración, tarifas y propinas. Cada hallazgo se registrará como descripción, asociación, hipótesis o inconcluso; ningún patrón se presentará como explicación causal.

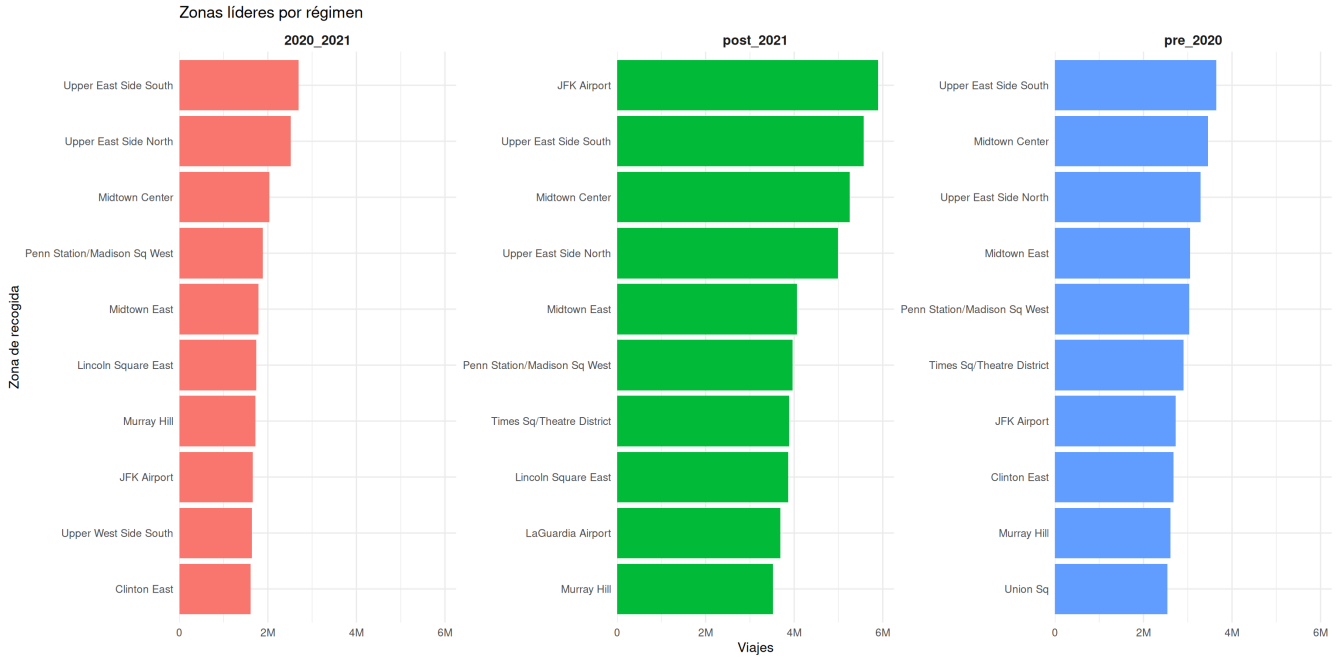


La demanda está concentrada espacialmente, aunque el ranking acumulado oculta cambios importantes entre períodos. La comparación por régimen que sigue evita convertir esa agregación histórica en una clasificación permanente de zonas.

Estabilidad entre regímenes



Los regímenes separan una dinámica previa a 2020, el período 2020–2021 y la recuperación posterior. El volumen mensual medio documentado es de 7.05 M, 2.31 M y 3.31 M viajes, respectivamente; se trata de una descripción de la fuente, no de una atribución causal.



Las zonas líderes no son estables entre regímenes. Por ejemplo, Upper East Side South lidera antes de 2020 y durante 2020–2021, mientras que JFK Airport lidera en el período posterior a 2021. El hallazgo respalda segmentar los análisis geográficos por período.

Economía observada y asociaciones

```
# A tibble: 6 x 4
  regime distance_total_corre~1 distance_duration_co~2 fare_tip_correlation
  <chr>                   <dbl>                  <dbl>                <dbl>
1 2020_~               0.000649              0.00113                0.0252
2 post_~               0.00239               0.0000504             -1.000
3 pre_2~               0.0349                0.0500                 0.586
4 2020_~               0.930                 0.768                  0.499
5 post_~               0.915                 0.781                  0.612
6 pre_2~               0.931                 0.775                  0.559
# i abbreviated names: 1: distance_total_correlation,
#   2: distance_duration_correlation
```

Las correlaciones describen co-movimiento en los registros; no identifican un efecto de distancia, tarifa o propina sobre otro resultado.

```
# A tibble: 18 x 6
   regime    payment_type    trips mean_distance  mean_tip mean_total
   <chr>            <dbl>    <dbl>         <dbl>     <dbl>      <dbl>
 1 2020_2021            1 39942236        2.94    2.98          19.5
 2 2020_2021            2 12817526        2.91    0.000380      15.9
 3 2020_2021            0  2288662       63.5     2.02          32.4
 4 2020_2021            3   298622        2.31    0.00368       32.3
 5 2020_2021            4   203437        2.59    0.0412        24.5
 6 2020_2021            5       19        3.66    0             15.6
 7 post_2021            1 90393053        3.55    4.07          27.4
 8 post_2021            2 19707704        3.47    0.00192       22.5
 9 post_2021            0  6768891       29.7    28.0           26.4
10 post_2021            4  1536857        3.50    0.0620        26.8
11 post_2021            3   726913        2.66    0.0290        22.3
12 post_2021            5       12        1.18    0             10.4
13 pre_2020             1 60620130        3.05    3.05          20.3
14 pre_2020             2 22894687        2.82    0.000301      16.1
15 pre_2020             3   447216        2.49    0.320         24.9
16 pre_2020             0   444383        9.87    0.0616        43.6
17 pre_2020             4   186580        2.58    0.0128        20.8
18 pre_2020             5       33        0.0394  0.0606         1.22
```

Los perfiles de pago y las asociaciones económicas cambian entre regímenes. Los importes negativos y extremos se auditan y la sensibilidad acotada está disponible en `reports/economic_sensitivity.csv`; por tanto, ninguna correlación se traduce en una regla de tarifa, incentivo o rentabilidad.

Rutas y hallazgos no cerrados

```
# A tibble: 30 x 4
   regime    pickup_name           dropoff_name           trips
   <chr>     <chr>                 <chr>                  <dbl>
 1 2020_2021 Upper East Side South Upper East Side North 399412
 2 2020_2021 Upper East Side North Upper East Side South 341936
 3 2020_2021 Upper East Side North Upper East Side North 293312
 4 2020_2021 Upper East Side South Upper East Side South 279437
 5 2020_2021 N/A                   N/A                   217166
 6 2020_2021 Upper West Side South Upper West Side North 164770
 7 2020_2021 Upper West Side South Lincoln Square East   155390
 8 2020_2021 Lenox Hill West       Upper East Side North 153595
 9 2020_2021 Lincoln Square East   Upper West Side South 145789
10 2020_2021 Upper East Side South Midtown Center        142907
# i 20 more rows
```

Las rutas frecuentes describen los trayectos observados más comunes dentro de cada régimen. La concentración por zona, rutas y pagos se conserva como exploración descriptiva: no se atribuye a capacidad, conducta de conductores, precios, clima, vuelos ni políticas, variables no observadas en esta fuente.

Matriz de evidencia y ramas exploradas

```
# A tibble: 6 x 6
  question                  population method evidence_type status decision
  <chr>                     <chr>      <chr>  <chr>         <chr>  <chr>
1 ¿La cobertura fuente es ~ 72 Parque~ manif~ descriptiva   compl~ continu~
2 ¿Como cambia la demanda ~ viajes co~ perfi~ descriptiva   compl~ continu~
3 ¿Como cambia la geografi~ zonas y r~ conce~ descriptiva   compl~ continu~
4 ¿Que relaciones economic~ viajes an~ distr~ asociativa    incon~ fare_ti~
5 ¿Se puede pronosticar de~ ciudad y ~ valid~ predictiva    aprob~ lag_cal~
6 ¿Se pueden recomendar in~ no observ~ evalu~ inconclusa    cerra~ no apta~
```

La matriz conserva qué preguntas recibieron evidencia suficiente y cuáles quedan abiertas. Sirve como contrato de alcance para que una etapa posterior no convierta un resultado descriptivo en una recomendación no respaldada.

Análisis predictivo: evaluación temporal

La predicción sólo se ejecutará tras aprobar los controles anteriores. El candidato inicial es demanda agregada por hora con horizontes de 1 a 24 horas. Se reservará el último 10 % cronológico como prueba final; en el 90 % previo se usarán ventanas expansivas. Las variables admitidas serán calendario conocido y rezagos disponibles al instante de pronóstico.

Se comparan baselines ingenua, estacional diaria y semanal frente a un modelo de rezagos y calendario. Las métricas son RMSE, MAE, WAPE, sesgo y cobertura de intervalos por horizonte. Un candidato sólo se considera apto cuando supera su baseline bajo la misma prueba temporal final.

```
# A tibble: 11 x 8
   series   best_rmse selected_model all_horizons_have_metrics any_rmse_na
   <chr>        <dbl> <chr>          <lgl>                     <lgl>
 1 city        197.   lag_calendar   TRUE                      FALSE
 2 zone_132      9.81 lag_calendar   TRUE                      FALSE
 3 zone_138      1.62 lag_calendar   TRUE                      FALSE
 4 zone_142      2.92 lag_calendar   TRUE                      FALSE
 5 zone_161      5.32 lag_calendar   TRUE                      FALSE
 6 zone_162      3.81 lag_calendar   TRUE                      FALSE
 7 zone_170      5.22 lag_calendar   TRUE                      FALSE
 8 zone_186      8.06 lag_calendar   TRUE                      FALSE
 9 zone_230     11.2  lag_calendar   TRUE                      FALSE
10 zone_236      2.02 lag_calendar   TRUE                      FALSE
11 zone_237      3.68 lag_calendar   TRUE                      FALSE
# i 3 more variables: any_na_predictions <lgl>, gate <chr>,
#   test_cut_epoch <dbl>
```

Las once series evaluadas quedan en `forecast_candidate_approved`: `lag_calendar` supera las baselines bajo la misma partición temporal. Esto habilita un componente de pronóstico histórico con monitoreo y reentrenamiento; no convierte el modelo en evidencia causal ni en una regla para intervenir sobre precios, flota o incentivos.

```
# A tibble: 33 x 10
   series   model      horizon  rmse   mae   wape     bias coverage80     n
   <chr>    <chr>        <dbl> <dbl> <dbl>  <dbl>    <dbl>      <dbl> <dbl>
 1 city     lag_calen~       1 616.  542.  0.101   115.         0.495   109
 2 city     lag_calen~       6 724.  545.  0.0728 -131.         0.963   109
 3 city     lag_calen~      24 957.  714.  0.144   224.         0.917   109
 4 zone_132 lag_calen~       1  25.5  19.7 0.137    -4.34       0.945   109
 5 zone_132 lag_calen~       6  63.3  52.5 0.127   -35.8        0.422   109
 6 zone_132 lag_calen~      24  28.8  20.3 0.158    -8.27       1       109
 7 zone_138 lag_calen~       1  42.0  32.3 0.139   -16.9        0.716   109
 8 zone_138 lag_calen~       6  70.9  58.7 0.207   -39.4        0.220   109
 9 zone_138 lag_calen~      24  49.1  37.5 0.218   -17.7        0.752   109
10 zone_142 lag_calen~       1  25.3  20.1 0.119     0.952      0.257   109
# i 23 more rows
# i 1 more variable: n_na_pred <dbl>
```

La evaluación reserva el último 10% cronológico post-2021 y selecciona las diez zonas sólo dentro del entrenamiento. La partición reproducible es la siguiente:

```
# A tibble: 3 x 7
  split               start_utc     end_utc n_hours share_pct regime note
  <chr>               <chr>         <chr>     <dbl>     <dbl> <chr>  <chr>
1 entrenamiento (base) 2022-01-01 U~ 2024-0~   18938        72 post_~ Mode~
2 validacion           2024-02-29 0~ 2024-0~    4735        18 post_~ Usad~
3 prueba final         2024-09-13 0~ 2024-1~    2631        10 post_~ 10% ~
```

La validación sólo respalda el uso predictivo dentro de la población, horizonte y período documentados. Fuera de esos límites, o si se degrada el desempeño, la aplicación debe volver a presentar el resultado como histórico hasta reentrenar y reevaluar el modelo.

Análisis prescriptivo condicionado

La evidencia disponible no identifica efectos de capacidad, incentivos, precios, flota o intervenciones. En consecuencia, no se recomienda una acción operativa ni se construyen escenarios de intervención. El único resultado prescriptivo defendible es un **no-go**: usar el análisis como diagnóstico histórico y no usarlo para decidir incentivos o capacidad sin datos de oferta, coste y resultado causal.

```
# A tibble: 5 x 5
  branch    status evidence_summary reason_for_status requirement_to_reopen
  <chr>     <chr>  <chr>            <chr>              <chr>
1 Calidad ~ apta   72 periodos val~ Los datos son tr~ Cualquier cambio de ~
2 Descript~ apta   Perfiles mensua~ El analisis desc~ No requiere reapertu~
3 Economic~ incon~ fare_tip_correl~ Los extremos no ~ Validar que la vista~
4 Predicti~ no ap~ Ningun candidat~ lag_calendar tuv~ (1) ventana expansiv~
5 Prescrip~ cerra~ No existen vari~ Una asociacion o~ Requiere datos de of~
```

Cada rama conserva el criterio necesario para reabrirla. Esto hace explícito que una recomendación operacional requeriría evidencia adicional, no una reinterpretación más fuerte de los mismos registros.

Hallazgos y conclusiones

F01 — Calidad e integridad

Tipo de evidencia: descriptiva.
Hallazgo: La fuente es trazable; 72 periodos mensuales validados por bytes y SHA-256. Las anomalias temporales se diferencian en dos metricas distintas.
Resultado: 259,287,888 viajes; 10,927 con mes fuente no coincidente; 2,087 fuera del rango global. 66,197 viajes con firma de negocio duplicada. Sin trip_id unico; la firma es una aproximacion.
Límite: Las dos metricas temporales no son el mismo conjunto de registros. La firma de duplicados es aproximacion; sin trip_id la medicion exacta es imposible.
Conclusión: La fuente es apta para analisis agregado bajo las reglas documentadas en temporal_anomaly_definitions.csv y transformation_contract.csv.

F02 — Demanda temporal

Tipo de evidencia: descriptiva.
Hallazgo: El volumen mensual medio difiere marcadamente entre regimenes temporales.
Resultado: Promedio mensual: pre-2020 7.05 M; 2020-2021 2.31 M; post-2021 3.31 M viajes.
Límite: La segmentacion describe cambios en la serie; no identifica su causa.
Conclusión: No se debe asumir una unica dinamica estable en toda la historia.

F03 — Geografia

Tipo de evidencia: descriptiva.
Hallazgo: La zona lider observada cambia entre regimenes. La persistencia de las top-10 zonas entre regimenes esta cuantificada en zone_top10_persistence.csv.
Resultado: 2020_2021: Upper East Side South (Manhattan); post_2021: JFK Airport (Queens); pre_2020: Upper East Side South (Manhattan)
Límite: El conteo de viajes no mide oferta, accesibilidad ni demanda no satisfecha.
Conclusión: La concentracion espacial merece analisis por regimen; no una clasificacion unica para todo el periodo.

F04 — Economia y pagos

Tipo de evidencia: asociativa.
Hallazgo: Las correlaciones economicas crudas muestran valores anomalos post-2021 que indican extremos o registros especiales. La vista acotada con filtros explicitos muestra correlaciones distintas.
Resultado: fare_tip_correlation cruda post-2021 = -1 (indica extremos); acotada = 0.612. Ver economic_sensitivity.csv para comparacion completa.
Límite: Importes negativos, extremos y variables no observadas impiden interpretacion causal. La correlacion cruda no es confiable sin filtrar extremos.
Conclusión: Rama economica inconclusa tras diagnostico de extremos. Usar economic_sensitivity.csv para comparar vistas cruda vs. acotada.

F05 — Prediccion

Tipo de evidencia: predictiva.
Hallazgo: lag_calendar supero las baselines en 11 de 11 series bajo la misma evaluacion temporal.
Resultado: Gate de 11 series: 0 con evidencia incompleta (RMSE NA o predicciones ausentes); 0 donde baseline fue mejor; 11 con candidato aprobado. ARIMA/fable: evaluated_24h_validation_diagnostic_only (diagnostico parcial 24h, no comparable).
Límite: ARIMA/fable solo tiene diagnostico parcial (24h, no comparable). Intervalos calibrados por horizonte. Hora calculada desde epoch real. 3 horas sin observacion en datos analiticos, rellenas con 0 por necesidad de grilla continua.
Conclusión: 11 de 11 series seleccionaron lag_calendar y superaron las baselines en la evaluacion temporal. El pronostico puede incluirse como funcion historica con monitoreo y reentrenamiento; no identifica efectos causales ni justifica decisiones operativas por si solo.

F06 — Prescriptiva

Tipo de evidencia: inconclusa.
Hallazgo: No hay evidencia para recomendar capacidad, incentivos, precios o flota.
Resultado: No existen variables de oferta, coste, intervencion, clima, vuelos ni resultados causales.
Límite: Una asociacion o pronostico historico no identifica el efecto de intervenir.
Conclusión: La salida prescriptiva correcta es no recomendar acciones; solo informar limites y evidencia disponible. Ver data_gaps.csv.

La evidencia congelada se cierra como un análisis integral reproducible, descriptivo y diagnóstico, con una rama predictiva temporalmente validada para las once series evaluadas. La actualización local amplía la

cobertura descriptiva hasta 2026-09, pero no amplía por sí sola la validación predictiva ni convierte el resultado en evidencia causal.

Conclusión de cierre

El análisis congelado entrega una base histórica trazable de 259,287,888 viajes y la actualización local registra 341,589,889 viajes publicados desde 2019-01 hasta 2026-09. La transición a MVP debe preservar el contrato de validación: puede combinar exploración histórica de cobertura, demanda, zonas, rutas, pagos y calidad con pronósticos de corto horizonte claramente etiquetados. No debe ofrecer recomendaciones de flota, tarifas ni incentivos.

Límites y transición

Estos datos permiten describir viajes registrados y evaluar pronóstico de demanda histórica. No contienen una medición suficiente de oferta, capacidad, costes operativos, incentivos ni efectos causales. Por ello no se harán recomendaciones de precios, flota o incentivos.

El flujo fue ejecutado desde una sesión R limpia, los artefactos se regeneraron y las pruebas automatizadas se validaron antes del cierre. Una decisión posterior sobre MVP debe consumir esta evidencia congelada y no modificar el análisis.

```
# A tibble: 7 x 3
  question_today_unanswerable                       data_needed why_needed
  <chr>                                             <chr>       <chr>
1 Cuantos conductores/vehiculos operaban en cada zo~ Registros ~ Sin ofert~
2 Cual es el efecto de un cambio de tarifa sobre la~ Precios hi~ Sin varia~
3 Como afectan los incentivos a conductores al volu~ Incentivos~ Sin la va~
4 Que rol juegan el clima y los eventos sobre la de~ Datos hora~ La demand~
5 Cuantos vuelos llegan al JFK/LGA/EWR?              Datos de t~ La demand~
6 Cuales son los costes operativos del conductor?    Datos de c~ Sin coste~
7 Que paso con los conductores que abandonaron dura~ Datos de r~ La recupe~
```

La tabla final identifica las variables que harían posible ampliar el alcance en el futuro. Hasta que esas fuentes se incorporen con un diseño de evaluación adecuado, los límites anteriores son parte del resultado, no trabajo pendiente oculto.